Лекція 1

Введення в дисципліну. Мета та задачі дисципліни “Інтелектуальний аналіз даних”. Основні визначення

Видобуток даних - Data Mining

OLAP (Online Analytic Processing) - системи надають аналітику засоби перевірки гіпотез при аналізі даних. При цьому основним завданням аналітика є генерація гіпотез. Він вирішує це завдання, ґрунтуючись на своїх знаннях та досвіді. Однак знання є не тільки у людини, але і в накопичених даних, які піддаються аналізу. Такі знання часто називають "прихованими", оскільки вони містяться в гігабайтах і терабайтах інформації, які людина не в стані досліджувати самостійно. У зв'язку з цим існує висока ймовірність випустити з під уваги важливі гіпотези, які можуть принести значну користь.

Очевидно, що для виявлення прихованих знань необхідно застосовувати спеціальні методи автоматичного аналізу, за допомогою яких на практиці добувають знання з нагромаджень різної інформації. Цей напрям отримав назву видобуток даних або Data Mining. Класичне визначення цього терміна дав в 1996 р. один із засновників цього напрямку - Григорій Пятецкий-Шапіро: Data Mining – це дослідження і виявлення "машиною", пристроєм (за допомогою алгоритмів, засобів штучного інтелекту) в "сирих" даних прихованих знань, які раніше не були відомі, нетривіальні, практично корисні, доступні для інтерпретації людиною.

В даний час технологія Data Mining представлена цілим рядом комерційних і вільно розповсюджуваних програмних продуктів. Достатньо повний і регулярно оновлюваний список цих продуктів можна знайти на сайті **www.kdnuggets.com**, присвяченому Data Mining. Впорядкувати програмні продукти Data Mining можна за тими ж принципами, що закладені в основу класифікації самої технології. Однак подібна класисифікацію не матиме практичної цінності. Внаслідок високої конкуренції на ринку і прагнення до повноти технічних рішень багато з продуктів Data Mining охоплюють буквально всі аспекти застосування аналітичних технологій. Тому доцільніше класифікувати продукти Data Mining по тому, яким чином вони реалізовані і, відповідно, який потенціал для інтеграції вони надають. Очевидно, що і це умовність, оскільки такий критерій не дозволяє окреслити чіткі межі між продуктами. Проте у подібної класифікації є одна безсумнівна перевага. Вона дозволяє швидко прийняти рішення про вибір того чи іншого готового рішення при ініціалізації проектів в галузі аналізу даних, розробки систем підтримки прийняття рішень, створення сховищ даних і т. д.

Отже, продукти Data Mining умовно можна розділити на три великі категорії:

- входять, як невід'ємна частина, в системи управління базами даних;
- бібліотеки алгоритмів Data Mining із супутньою інфраструктурою;
- коробкові або настільні рішення ("чорні ящики").

Продукти перших двох категорій надають найбільші можливості для інтеграції і дозволяють реалізувати аналітичний потенціал практично в будь-якому додатку в будь-якій області. Коробкові додатки, в свою чергу, можуть надавати деякі унікальні досягнення в області Data Mining або бути спеціалізованими для якої-небудь конкретної сфери застосування. Проте в більшості випадків їх проблематично інтегрувати в більш широкі рішення.

Включення аналітичних можливостей до складу комерційних систем управління базами даних є закономірною і має величезний потенціал тенденцією. Дійсно, де, як не в місцях концентрації даних, має найбільший сенс розміщувати засоби їх обробки. Виходячи з цього принципу, функціональність Data Mining зараз реалізовано в наступних комерційних базах даних:

- Oracle;
- Microsoft SQL Server;
- IBM DB2.

Кожна з названих СУБД дозволяє вирішувати основні завдання, пов'язані з аналізом даних, і має гарні можливості для інтеграції. Однак тільки Oracle може вважатися дійсно

аналітичної платформою. Крім реалізації функціональності Data Mining, Oracle має потужні засоби для аналізу неструктурованої текстової інформації (Oracle Text), інформації, що має мережну модель організації (Oracle Network Data Models), та інформації, що має просторові атрибути (Oracle Spatial Topology). Таким чином, використовуючи СУБД Oracle як платформу для побудови аналітичної системи, можна вирішити практично будь-яке поставленне завдання: від побудови рекомендаційних систем для інтернет-магазинів до багатофункціональних систем підтримки прийняття рішень для різних державних і силових відомств. Далі наводиться огляд основних аналітичних можливостей Oracle.

Oracle Data Mining включає в себе чотири найбільш потужних і зарекомендую ¬ вавших себе алгоритму класифікації (supervised learning):

- Naive Bayes (NB) - використовує теорію ймовірності для класифікації об'єктів;
- Decision Trees - класифікує об'єкти шляхом побудови дерев рішень;
- Adaptive Bayes Networks (ABN) - розширений варіант алгоритму NB;
- Support Vector Machines - використовує теорію обчислення близькості векторів для класифікації об'єктів.

Для вирішення задач кластеризації і асоціативного аналізу Unsupervised learning) в Oracle застосовується п'ять алгоритмів:

- Enhanced k-Means Clustering - для виявлення груп схожих об'єктів;
- Orthogonal Partitioning Clustering- для кластеризації методом ортогонального розподілу;
- Anomaly Detection - для виявлення рідкісних викликаючих підозру подій (аномалій);
- Association Rules - для виявлення шаблонів у подіях;
- Nonnegative Matrix Factorization (NMF) - для зменшення кількості атрибутів.

Oracle також включає в себе алгоритм Minimum Description Length (MDL) для вирішення проблеми важливості атрибутів. З його допомогою можна визначити ті атрибути, які мають найбільший вплив на залежні поля або атрибути.

В останні роки особливу важливість придбали завдання, пов'язані з обробкою великих масивів генетичної інформації. Для їх вирішення Oracle пропонує алгоритм BLAST (Basic Local Alignment Search Technique), дозволяючий в геномних даних відшукувати послідовності, які найбільш точно відповідають певним послідовностям.

Доступ до функціональності Data Mining в Oracle здійснюється або засобом розширення мови SQ) L, або за допомогою прикладного програмного інтерфейсу на Java. Відзначимо, що даний інтерфейс сумісний з специфікацією JDM.

Аналіз текстової інформації в Oracle представлений цілим рядом технологій, які забезпечують наступні можливості:

- якісний повнотекстовий пошук:
  - ❖ сортування результатів пошуку за релевантністю;
  - ❖ автоматичне приведення слів в запиті до нормальної граматичної форми (стеммінг);
  - ❖ пошук із зазначенням розташування фрагмента в тексті (заголовках, параграфах);
  - ❖ пошук фраз і точних збігів слів;
  - ❖ використання логічних операторів (І, АБО і т. д.) при складанні запитів;
  - ❖ автоматична фільтрація шумових слів у запиті (союзи, частки тощо);
  - ❖ автоматичне розширення запитів семантично близькими словами (синоніми та ін);
  - ❖ автоматичне розширення запитів клавіатурної близькими словами (друкарські помилки);
  - ❖ розширення запитів за допомогою масок (wildcard символи: '*', '?');
  - ❖ пошук документів із зазначеної теми;
  - ❖ нечіткий пошук (співзвучні слова, типові помилки і т. д.);
- автоматичне визначення теми документа;
- автоматичне анотування документів;
- управління базами знань системи (тезауруси, словники тим, синоніми і т. д.);
- автоматична класифікація вхідних документів;

- пошук груп схожих документів (кластеризація);
- підтримка декількох природних мов (російська, англійська);
- автоматичне розпізнавання поширених форматів (Word, XML, PDF і т. д.).

Таким чином, Oracle Text дозволяє будувати системи обробки неструкту-центрувати інформації будь-якого рівня: від пошукового порталу до інтелекту туальний систем документообігу. В даний час Oracle Text підтримує безліч мов, у тому числі російську.

Аналіз мережевої інформації в Oracle дозволяє виявляти неявні зв'язки між об'єктами, організованими в мережеві структури або графи. На перший погляд це може здатися досить абстрактною областю застосування, однак подібні можливості є вкрай затребуваними, наприклад, в силових відомствах. Всілякі служби розвідки, розслідування податкових злочинів і виявлення нелегального фінансування тероризму, поліцейські організації і т. д. розташовують великими базами даних, де фіксуються певні аспекти діяльності об'єктів. Зокрема, їх безпосередні і видимі зв'язки один з одним. Очевидно, що крім видимих і зафіксованих зв'язків існують також неявні, опосередковуванні зв'язки. Вони то і становлять найбільший інтерес для розслідування.

Для вирішення такого завдання Oracle Network Data Models містить таку функціональність з аналізу графів:

- визначити всі шляхи, що з'єднують два даних вузла;
- знайти всі вузли, досяжні з даного вузла;
- знайти всі вузли, з яких можливо потрапити в даний вузол:
- визначити найкоротший шлях між вузлами;
- визначити найбільш ефективний шлях, що включає вказані вузли;
- визначити вузли, в які можна потрапити з даного вузла в межах вказаної вартості шляху;
- визначити, досяжний чи цільової вузол з даного вузла;
- визначити мінімальну покриває дерево;
- визначити найближчих сусідів (за кількістю) для даного вузла.

Технології аналізу просторової інформації (Oracle Spatial Topology) містять весь необхідний інструментарій для побудови геоінформаційних систем різних рівнів складності.

Серед численних бібліотек Data Mining, що існують в даний момент на ринку, особливо слід виділити систему з відкритим кодом Weka. Це динамічно розвивається, велика колекція різноманітних алгоритмів, розроблена в новозеландському університеті Waikato. Вона реалізована на мові Java, має досить простий програмний інтерфейс, забезпечена графічною оболонкою і добре документована. Все це, включаючи вільне розповсюдження, робить бібліотеку Weka виключно популярною. Серед недоліків бібліотеки можна відзначити недостатню увагу розробників до проблеми масштабованості. Це означає, що робота зі надвеликими даними, що вимагає специфічного підходу до розробки та оптимізації існуючих алгоритмів, в Weka практично не виконана.

Використання коробкових комерційних продуктів має найбільший сенс у тих проектах, де інтелектуальний аналіз даних є основної метою, а не супроводжує побудова більш великої системи, наприклад, системи підтримки прийняття рішень. У цьому випадку вибір конкретного продукту може визначатися безліччю чинників - від предметної орієнтації до ціни.

Списки продуктів в таблиці впорядковані за ступенем убування "популярності". Як видно, з року в рік лідирують одні й ті ж інструменти, хоча загальний список налічує не менше сотні найменувань. Очевидно, що при виборі відповідного засобу Data Mining в першу чергу слід роздивлятись і порівнювати між собою перераховані продукти.

Практичне застосування Data Mining

Інтернет-технології

У системах електронного бізнесу, де особливу важливість мають питання залучення і утримання клієнтів, технології Data Mining часто застосовуються для побудови рекомендаційних систем інтернет-магазинів і для вирішення проблеми персоналізації відвідувачів web-сайтів. Рекомендації товарів і послуг, побудовані на основі закономірностей в покупках клієнтів, володіють величезною переконливою силою. Статистика показує, що

майже кожний відвідувач магазину Amazon не упускає можливості подивитися на те, що ж купили "Customers who bought this book also bought: ..." ("Ті, хто купив цю книгу, також купили .. . "). Персоналізація клієнтів або, іншими словами, автоматичне розпізнавання приналежності клієнта до визначенні цільової аудиторії дозволяє компанії проводити більш гнучку маркетингову політику. Оскільки в електронній комерції гроші і платіжні системи теж електронні, то важливим завданням стає забезпечення безпеки при операціях з пластиковими картками. Data Mining дозволяє виявляти випадки шахрайства (fraud detection). В області електронної комерції також залишаються справедливими все методології Data Mining, розроблені для звичайного маркетингу. З іншого боку, ця область тісно пов'язана з поняттям Web Mining.

Специфіка Web Mining полягає в застосуванні традиційних технологій Data Mining для аналізу вкрай неоднорідною, розподіленої і великої за обсягом інформації, що міститься на web-сайтах. Тут можна виділити два напрямки: Web Content Mining і Web Usage Mining. В першому випадку мова йде про автоматичне пошуку й витягу якісної інформації з перевантажених "інформаційним шумом" джерел Інтернету, а також про всілякі засоби автоматичної класифікації і анотуванні документів. Даний напрямок також називають Text Mining. Web Usage Mining спрямований на виявлення закономірностей в поведінці користувачів конкретного web-сайту (групи вузлів), зокрема на те, які сторінки у якій часовій послідовності і якими групами користувачів запитуються.

Торгівля

Для успішного просування товарів завжди важливо знати, що і як продається, а також хто є споживачем. Вичерпну відповідь на перше питання дають такі засоби Data Mining, як аналіз ринкових кошиків і сиквенціальний аналіз. Знаючи зв'язку між покупками і тимчасові закономірності, можна оптимальним чином регулювати пропозицію. З іншого боку, маркетинг має можливість безпосередньо керувати попитом, але для цього необхідно знати якомога більше про споживачів - цільової аудиторії маркетингу. Data Mining дозволяє вирішувати завдання виділення груп споживачів зі схожими стереотипами поведінки, тобто сегментують ринок. Для цього можна застосовувати такі технології Data Mining, як кластеризація і класифікація.

Сіквенціальний аналіз допомагає торговельним підприємствам приймати рішення про створення товарних запасів. Він дає відповіді на питання типу "Якщо сьогодні покупець придбав відеокамеру, то через якийсь час він найімовірніше купить нові батарейки і плівку?".

Телекомунікації

Телекомунікаційний бізнес є однією з найбільш динамічно розвиваються областей сучасної економіки. Можливо, тому традиційні проблеми, з якими стикається у своїй діяльності будь-яка компанія, тут відчуваються особливо гостро. Наведемо деякі цифри. Телекомунікаційні компанії працюють в умовах жорсткої конкуренції, що проявляється в щорічному відтоку близько 25% клієнтів. При цьому відомо, що утримати клієнта в 4-5 разів дешевше, ніж залучити нового, а ось повернути клієнта який пішов буде коштувати вже в 50-100 разів більше, ніж його утримати. Далі, як і в цілому в економіці, справедливо правило Парето - тільки 20% клієнтів приносять компанії основний дохід. Крім цього існує ряд клієнтів, що завдають компанії прямої шкоди. 10% всього доходу телекомунікаційної індустрії в рік втрачається через випадки шахрайства, що складає $ 4 млрд. Таким чином, використання технологій Data Mining, спрямованих як на аналіз прибутковості і ризику клієнтів (churn prevention), так і на захист від шахрайства, заощадить компанії величезні кошти.

Ще один з найпоширеніших способів використання методів Data Mining-це аналіз записів про докладних характеристиках викликів. Призначення такого аналізу-виявлення категорій клієнтів зі схожими стереотипами користування послугами та розробка привабливих наборів цін і послуг.

Промислове виробництво

Промислове виробництво створює ідеальні умови для застосування технологій Data Mining. Причина - у самій природі технологічного процесу, який повинен бути відтворюваним і контрольованим. Всі відхилення протягом процесу, що впливають на якість вихідного результату, також знаходяться в заздалегідь відомих межах. Таким чином, створюється статистична стабільність, першорядну важливість якої відзначають в роботах по класифікації. Природно, що в таких умовах використання Data Mining здатне дати кращі результати, ніж, приміром, при прогнозуванні того що клієнти телекомунікаційних компаній підуть від них. В останньому випадку причинами догляду можуть стати не схильності до зміни місць, властиві цілим групам абонентів, а зовнішні, абсолютно випадкові, і тому не утворюють ніяких закономірностей обставини (наприклад, вдало проведена конкурентами рекламна кампанія, економічна криза і т. д). Досвід роботи компаній, що пропонують рішення Data Mining для промислового виробництва, також свідчить про успішність такої інтеграції. Прикладом застосування Data Mining в промисловості може бути прогнозування якості виробу в залежності від замірювань параметрів технологічного процесу.

Медицина

У медичних і біологічних дослідженнях, так само як і в практичній медицині, спектр вирішуваних завдань настільки широкий, що можливо використання будь-яких методологій Data Mining. Прикладом може служити побудова діагностичної системи або дослідження ефективності хірургічного втручання.

Відомо багато експертних систем для постановки медичних діагнозів. Вони побудовані головним чином на основі правил, що описують поєднання різних симптомів окремих захворювань. За допомогою таких правил впізнають не тільки, на що хворий пацієнт, але і як потрібно його лікувати. Правила допомагають вибирати засоби медикаментозного впливу, визначати показання/протипоказання, орієнтуватися в лікувальних процедурах, створювати умови найбільш ефективного лікування, передбачати наслідки призначеного курсу лікування і т. п. Технології Data Mining дозволяють виявляти в медичних даних шаблони, складові основу зазначених правил.

Одним з найбільш передових напрямків медицини є біоінформатика-область науки, що розробляє і застосовує обчислювальні алгоритми для аналізу та систематизації генетичної інформації з метою з'ясування структури і функції макромолекул, подальшого використання цих знань для пояснення різних біологічних явищ і створення нових лікарських препаратів (Drug Design). Об'єктом дослідження біоінформатики є величезні обсяги інформації про послідовності ДНК та первинної структурі білків, що з'явилися в результаті вивчення структури геномів мікроорганізмів, ссавців і людини. Абстрагуючись від конкретного змісту цієї інформації, її можна розглядати як набір генетичних текстів, що складаються з протяжних вільних послідовностей. Виявлення структурних закономірностей в таких послідовностях входить в число завдань, ефективно вирішуються засобами Data Mining, наприклад за допомогою сіквенціального і асоціативного аналізу. Основна область практичного застосування біоінформатики - це розробка ліків нового покоління, які повністю змінять сучасну медицину. Сьогодні розробка одного препарату в США займає в середньому 10-12 років, а вартість становить $ 300-500 млн. Біоінформатика скорочує ці цифри вдвічі. Спираючись на апарат Data Mining біоінформатика може ще більше прискорити і здешевити дофармакологічну фазу дослідження нових препаратів.

Банківська справа

Класичним прикладом застосування Data Mining на практиці є вирішення проблеми про можливу некредитоспроможності клієнтів банку. Це питання, тривожить будь-якого співробітника кредитного відділу банку, можна вирішити й інтуїтивно. Якщо образ клієнта у свідомості банківського працівника відповідає його уявленню про кредитоспроможність клієнта, то кредит видавати можна, інакше - відмовити. За схожою схемою, але більш продуктивно і повністю автоматично працюють встановлені в тисячах американський банків системи підтримки прийняття рішень (Decision System Support) з вбудованою функціональністю Data Mining. Позбавлені суб’єктивної упередженості, вони спираються у

своїй роботі тільки на історичну базу даних банку, де записується детальна інформація про кожного клієнта і, в кінцевому підсумку, факт його кредитоспроможності. Класифікаційні алгоритми Data Mining обробляють ці дані, а отримані результати використовуються далі для прийняття рішень.

Аналіз кредитного ризику полягає, перш за все, в оцінці кредитоспроможності позичальника. Це завдання вирішується на основі аналізу накопиченої інформації, тобто кредитної історії "старих" клієнтів. За допомогою інструментів Data Mining (дерева рішень, кластерний аналіз, нейронні мережі тощо) банк може отримати профілі добросовісних і неблагонадійних позичальників. Крім того, можна класифікувати позичальника за групами ризику, а значить, не тільки вирішити питання про можливість кредитування, а й встановила ліміт кредиту, відсотки по ньому і термін повернення.

Шахрайство із кредитними картками є серйозною проблемою, оскільки збитки від нього вимірюються мільйонами доларів щорічно, а зростання кількості шахрайських операцій становить, за оцінками експертів, від 15 до 25% щорічно.

У боротьбі з шахрайством технологія Data Mining використовує стереотипи підозрілих операцій, створені в результаті величезної кількості транзакцій - як законних, так і неправомірних. Досліджується не тільки окремо взята операція, а й сукупність послідовних в часі транзакцій. Крім того, алгоритми і моделі (наприклад, нейронні мережі), які є в складі продуктів Data Mining, здатні тестуватися і самонавчатися. При спробі здійснення підозрілої операції засоби інтелектуального аналізу даних оперативно видають попередження про це, що дозволяє банку запобігти незаконні дії, а не видаляти їх наслідки. Використання технології Data Mining дозволяє зменшити число порушень на 20-30%.

Страховий бізнес

У страхуванні, також як в банківській справі і маркетингу, виникає завдання обробки великих обсягів інформації для визначення типових груп (профілів) клієнтів. Ця інформація використовується для того, щоб пропонувати певні послуги страхування з найменшим для компанії ризиком і, можливо, з користю для клієнта. За допомогою технологій Data Mining також вирішується така часто зустрічається в страхуванні завдання, як визначення випадків шахрайства.

Інші області застосування

Data Mining може застосовуватися практично скрізь, де виникає завдання автоматичного аналізу даних. Як приклад наведемо такі популярні напрями, як аналіз і наступна фільтрація спаму. а також розробка так званих віртуальних співрозмовників. Останні зараз являються не більше ніж екзотичним доповненням до інтерфейсу деяких сайтів, але передбачається, що в майбутньому вони можуть замінити собою call-центри компаній.