Лекція 2

Властивості видобутих знань. Класифікація задач Data Mining

Data Mining – це дослідження і виявлення "машиною", пристроєм (за допомогою алгоритмів, засобів штучного інтелекту) в "сирих" даних прихованих знань, які раніше не були відомі, нетривіальні, практично корисні, доступні для інтерпретації людиною.

Видобуті знання повинні мати наступні властивості:

- **Знання повинні бути нові, раніше невідомі.** Витрачати зусилля на відкриття знань, які вже відомі користувачеві, не є виправданим. Тому цінність представляють саме нові, раніше невідомі знання.
- **Знання повинні бути нетривіальні.** Результати аналізу повинні відображати неочевидні, несподівані закономірності у даних, виявляти так звані "приховані" знання. Результати, які могли б бути отримані більш простими способами (наприклад, візуальним переглядом), не виправдовують залучення потужних методів Data Mining.
- **Знання повинні бути практично корисні**. Знайдені знання повинні бути придатні для застосування на нових даних, з досить високим ступенем вірогідності отримання достовірного результату. Корисність полягає в тому, щоб ці знання могли принести певні позитивні результати при їх використанні.
- **Знання повинні бути доступні для розуміння людини**. Знайдені закономірності повинні мати логічне обґрунтування, повинні бути зрозумілими і логічними, в іншому випадку існує ймовірність, що вони є випадковими. Крім того, отримані знання повинні бути представлені в зрозумілому для людини вигляді.

В Data Mining для відображення отриманих знань служать певні моделі. Види моделей залежать від методів їх створення. Найбільш поширеними серед них є: правила, дерева рішень, кластери і математичні функції.

Класифікація задач Data Mining

Методи Data Mining допомагають вирішити багато завдань, з якими зіштовхується аналітик. До основних з них належать: класифікація, регресія, пошук асоціативних правил і кластеризація:

- Задача класифікації зводиться до визначення класу об'єкта по його характеристикам. Необхідно зауважити, що в цьому завданні множина класів, до яких може бути віднесений об'єкт, відомо заздалегідь.
- Задача регресії подібно задачі класифікації дає змогу визначити за відомим характеристикам об'єкта значення деякого його параметра. На відміну від завдання класифікації значенням параметра не є скінченним набором класів, а набором дійсних чисел.
- При пошуку асоціативних правил метою є знаходження частих залежностей (або асоціацій) між об'єктами або подіями. Знайдені залежності представляються у вигляді правил і можуть бути використані, як для кращого розуміння природи аналізованих даних, так і для передбачення появи певних подій.
- Задача кластеризації полягає в пошуку незалежних груп (кластерів) та їх характеристик у всьому наборі аналізованих даних. Вирішення цього завдання допомагає краще зрозуміти дані. Крім того, групування однорідних об'єктів дає змогу скоротити їх число, а отже, і полегшити аналіз.

Всі ці завдання за призначенням поділяються на описові і передбачувані.

Описові (descriptive) завдання приділяють увагу поліпшенню розуміння аналізованих даних. Ключовий момент в таких моделях - легкість і зрозумілість отриманих результатів для сприйняття людиною. Можливо, виявленні закономірності будуть специфічною рисою саме конкретних досліджуваних даних і більше ніде не зустрінуться, але вони все одно можуть бути

корисними і тому повинні бути відомими. До такого виду завдань відносяться кластеризація і пошук асоціативних правил.

Розв'язання п**ередбачуваних (predictive) завдань** розбивається на два етапи. На першому етапі на підставі набору даних з відомими результатами будується модель. На другому етапі вона використовується для передбачення результатів на підставі нових наборів даних. При цьому, природно, потрібно, щоб побудовані моделі працювали максимально точно. До даного виду завдань відносять завдання класифікації і регресії. Сюди можна віднести і завдання пошуку асоціативних правил, якщо результати рішення можуть бути використані для передбачення появи деяких подій.

Для виявлення знань в даних недостатньо просто застосувати методи Data Mining, хоча, безумовно, цей етап є основним в процесі інтелектуального аналізу. Весь процес складається з декількох етапів. Роздивимося основні з них, щоб продемонструвати, що без спеціальної підготовки аналітика методи Data Mining самі по собі не вирішують існуючих проблем. Отже, весь процес можна розбити на наступні етапи (рис. 2.1):

- розуміння і формулювання задачі аналізу;
- підготовка даних для автоматизованого аналізу (препроцессінг);
- Застосування методів Data Mining і побудова моделей
- перевірка побудованих моделей;
- інтерпретація моделей людиною.

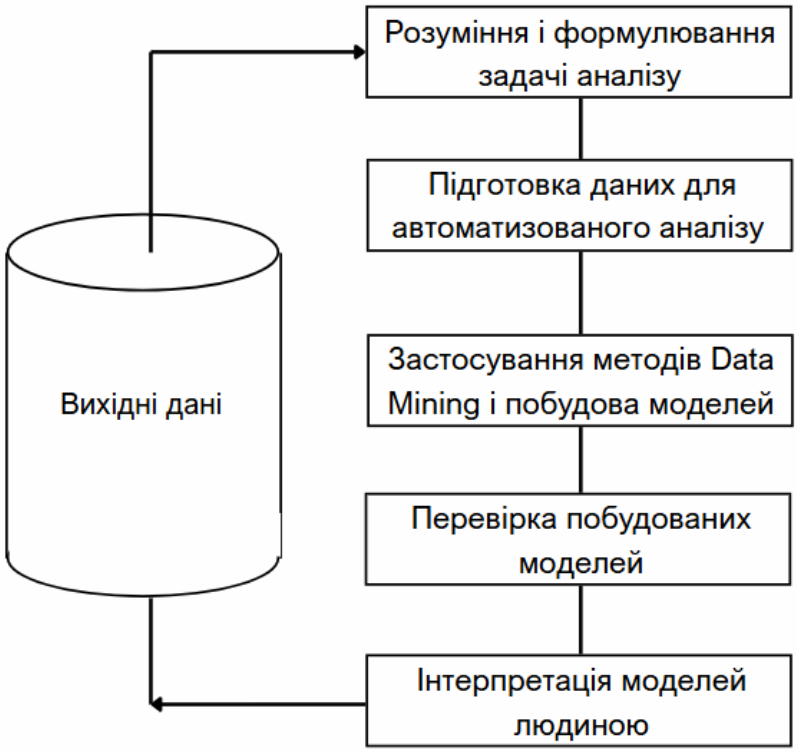


Рис. 2.1. Етапи інтелектуального аналізу

На першому етапі виконується осмислення поставленої задачі та уточнення цілей, які повинні бути досягнуті методами Data Mining. Важливо правильно сформулювати цілі і вибрати необхідні для їх досягнення методи, оскільки від цього залежить подальша ефективність всього процесу.

Другий етап полягає у приведенні даних до форми, придатної для застосування конкретних методів Data Mining. Даний процес далі буде описаний більш докладно, тут зауважимо тільки, що вид перетворень, здійснюємих над даними, багато в чому залежить від використовуваних методів, обраних на попередньому етапі.

Третій етап - це власне застосування методів Data Mining. Сценарії цього застосування можуть бути самими різними і можуть включати складну комбінацію різних методів, особливо якщо використовуються методи дозволяють проаналізувати дані з різних точок зору.

Наступний етап - перевірка побудованих моделей. Дуже простий і часто використовуваний спосіб полягає в тому, що всі наявні дані, котрі необхідно аналізувати, розбиваються на дві групи. Як правило, одна з них більшого розміру, інша меншого. На більшій групі, застосовуючи ті чи інші методи Data Mining, отримують моделі, а на меншій - перевіряють їх. За різницею в точності між тестової та навчальною групами можна судити про адекватність побудованої моделі.

Останній етап - інтерпретація отриманих моделей людиною з метою їх використання для прийняття рішень, додавання одержані правил і залежностей в базі знань і т. д. Цей етап часто передбачає використання методів, що знаходяться на стику технології Data Mining і технології експертних систем Від того, наскільки ефективним він буде, значною мірою залежить успіх вирішення поставленого завдання.

Цим етапом завершується цикл Data Mining. Остаточна оцінка цінності видобутого нового знання виходить за рамки аналізу, автоматизованого або традиційного, і може бути проведена тільки після втілення в життя рішення, прийнятого на основі здобутого знання, після перевірки нового знання практикою. Дослідження досягнутих практичних результатів завершує оцінку цінності видобутого засобами Data Mining нового знання.